

学校代码: 10246

学 号: 24210240291

復旦大學

硕 士 论 文 大 纲

(专业学位)

对抗微调为核心的 AI 文本对齐增强生成

Adversarial Fine-Tuning Centered AI Text
Alignment-Enhanced Generation

院 系: 计算与智能创新学院

专业学位类别(领域): 计算机技术

姓 名: 宋安洋

指 导 教 师: 冯瑞 研究员

完 成 日 期: 2026 年 6 月 1 日

指导小组成员

冯 瑞 研究员

张玥杰 教 授

程 颖 助理教授

赵瑞玮 青年副研究员

目 录

插图目录	iv
表格目录	v
摘要	vi
Abstract	vii
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 研究历史与现状	1
1.3 本文的主要工作	1
1.4 本文组织结构	2
第 2 章 相关技术与相关工作	3
2.1 预训练语言模型	3
2.1.1 大模型与其他预训练语言模型	3
2.1.2 大模型 RLHF 与 RLAIIF	3
2.2 AI 文本检测与粗粒度类人对齐	3
2.2.1 AI 文本检测器	3
2.2.2 AI 文本检测数据集与基准测试	4
2.2.3 粗粒度类人对齐	4
2.3 本章小结	5
第 3 章 对抗微调为核心的原生 AI 文本对齐增强研究	7
3.1 引言	7
3.2 算法设计与实现	7
3.2.1 目标领域、目标语言与生成器大模型选取设置	7
3.2.2 基于跨域交叉奖励的对抗性强化学习算法框架	7
3.2.3 对抗性强化学习与非训练对齐方法的集成增强	7
3.3 实验设置	8

3.3.1	任务定义	8
3.3.2	数据集	9
3.3.3	对比基线	9
3.3.4	评估指标	9
3.4	实验结果与分析	10
3.4.1	主要实验	10
3.4.2	消融实验	10
3.4.3	定量与定性分析	10
3.5	本章小结	10
第 4 章	AI 重写对齐增强中对抗微调的针对性改进研究	11
4.1	引言	11
4.2	算法设计与实现	11
4.2.1	目标领域、目标语言与生成器大模型选取设置	11
4.2.2	面向重写对齐的对抗型强化学习类人对齐奖励分数设计	11
4.2.3	面向重写质量的多奖励融合增强	12
4.3	实验设置	12
4.3.1	任务定义与评估方式	12
4.3.2	数据集	12
4.3.3	对比基线	12
4.4	实验结果与分析	13
4.4.1	主要实验	13
4.4.2	消融实验	13
4.4.3	定量与定性分析	13
4.5	本章小结	13
第 5 章	AI 文本对齐增强生成系统的设计、实现和测试	14
5.1	系统架构设计	14
5.2	系统实现	14
5.2.1	整体系统环境实现	14
5.2.2	AI 文本对齐增强生成算法服务实现	14
5.3	系统测试	14
5.3.1	功能测试	14
5.3.2	性能测试	14
5.4	本章小结	14

第 6 章 总结与展望	15
6.1 全文总结	15
6.2 未来展望	15
参考文献	16
致谢	23

插图目录

3-1	Overview of MAGA-Bench. The construction of the dataset encompasses 20 domains, 12 generators, 2 languages and 4 alignment methods. Selected detectors are evaluated on this dataset. Various decoding strategies are also employed, with details provided in Appendix ??.	8
3-2	GDARL and its integration with the Cross-Mutual Reward (CMR) component. The term GDARL serves as a collective designation for GDARL-like frameworks and also represents their most general form. The illustration depicts the two standard applications of CMR, namely GDARL-CDMR (Cross Domain Mutual Reward) and GDARL-CMMR (Cross Model Mutual Reward).	8
3-3	MAGA Pipeline, illustrating the construction process for the MAGA split of the MAGA dataset. MAGA split is the fully enhanced split that integrates all four alignment methods (see Table ??, Appendix ?? for detailed statistics of the splits).	9

表格目录

2-1 A comparison of the publicly available sources of machine-generated text. 6

4-1 注意：这个是 Beemo^[1] 列出的有关重写的 benchmark 对比的表。 . 12

摘 要

随着大语言模型的迭代升级，AI 生成文本在内容质量、行文流畅度与逻辑完整性等层面上不断持续提升。AI 生成文本与人类撰写文本的界限日渐模糊，依然存在句式过度工整、用词过度规范、逻辑过度完美等较为明显的机器属性，这也是现有 AI 检测器可对 AI 文本在一定程度上实现有效甄别的关键原因之一。这类高度标准化的文本输出，使得大模型在人机交互、内容创作、办公辅助等实际落地场景中生成的文本生硬刻板、缺少人文质感，用户使用体验欠佳。现有大模型拟人研究多聚焦细粒度、高精度拟人优化，不仅需要依托海量人类个性化文本数据集，又易出现过拟合、语义偏移、内容失真等问题，泛化性较差，难以适配通用场景。本文提出了一系列关于大模型和 AI 检测器对抗性强化学习实现粗粒度拟人的算法。所提算法具备双重价值：在应用层面，能够优化文本表现形式、提升内容亲和力，切实改善终端用户体验；在研究层面，多组攻防对照实验证实，经本文算法拟人化改造后的生成文本，能够促进 AI 检测器鲁棒性的发展，有助于规避和预防因 AI 生成门槛过低滋生的虚假新闻传播等滥用风险。

关键词：大语言模型；自然语言处理；大模型拟人化；大模型对齐；大模型安全；AI 文本检测；对抗微调；强化学习

中图分类号：TP391.1

Abstract

With the iterative upgrading of Large Language Models (LLMs), AI-generated text has continuously improved in terms of content quality, linguistic fluency, and logical coherence. While the boundary between AI-generated and human-written text is increasingly blurred, AI text still exhibits distinct machine attributes, such as overly structured sentence patterns, excessively standardized diction, and flawlessly rigid logic. This remains one of the key reasons why existing AI detectors can effectively identify AI-generated content to a certain extent. Such highly standardized textual outputs often render the generated content rigid and devoid of human touch in practical deployment scenarios—such as human-computer interaction, content creation, and office assistance—ultimately leading to a subpar user experience. Current research on LLM anthropomorphism predominantly focuses on fine-grained and high-precision optimization. This approach not only relies heavily on massive datasets of personalized human text, but is also prone to issues like overfitting, semantic drift, and content distortion, resulting in poor generalizability and difficulty in adapting to general scenarios. To address these limitations, this paper proposes a series of algorithms for coarse-grained anthropomorphism based on adversarial reinforcement learning between LLMs and AI detectors. The proposed algorithms possess dual value: 1. At the application level: They optimize the presentation of text and enhance content affinity, effectively improving the end-user experience. 2. At the research level: Multiple sets of empirical adversarial (attack-defense) experiments demonstrate that the generated text anthropomorphized by our algorithms can stimulate the robustness of AI detectors. This contributes to mitigating and preventing misuse risks, such as the spread of fake news fueled by the low barrier to AI generation.

Keywords: Large Language Model; Natural Language Processing; LLM Anthropomorphism; LLM Alignment; LLM Safety; AI Text Detection; Adversarial Fine-Tuning; Reinforcement Learning

CLC code: TP391.1

第 1 章 绪论

1.1 研究背景与意义

1. 剖析当前 AI 文本生成内容依然存在一些较为明显的机械化特征的痛点。
2. AI 文本质量的提升、生成的门槛与成本极低，导致滥用现象加剧。
3. 应用意义：优化文本表现形式、提升内容亲和力，改善用户体验。
4. 研究意义：促进 AI 检测器鲁棒性的发展，规避和预防滥用风险。

1.2 研究历史与现状

1. 大模型拟人化的研究目前主要集中于细粒度拟人^[2]。
 - 1.1. 介绍细粒度拟人，带有具体身份、生平经历等信息。
 - 1.2. 揭示细粒度拟人通用性不足的问题。
2. 对粗粒度拟人的研究主要集中于 AI 文本检测领域。
 - 2.1. 粗粒度拟人尚无通用的评估方式^[3-4]。
 - 2.2. 一些研究会将绕过 AI 文本检测器检测称作拟人化^[5]，但实际上这只是对某些检测器而言认定为像人类文本^[6]，并不等同于真正意义上的拟人。
 - 2.3. 但是根据 HC-Var 的理论^[7]，实际上我们可以通过 AI 文本检测过程中的攻防双边验证来判断生成文本是否更加粗粒度拟人，详见第 2 章 2.2.3 节的介绍。
3. 现有 AI 文本检测数据集与基准测试主要关注于数据整体分布的扩充，忽略了单文本生成过程的增强，RAID^[8] 尽管系统引入了大量基于规则的攻击方法，但破坏语义结果，这既不利于 RoBERTa 检测器训练过程的语义学习，不利于整体泛化检测能力的提升，也不拟人，几乎没有干扰人类阅读对 AI 文本的判别。详见第 2 章 2.2.2 节的介绍。我们的拟人增强，还有助于进一步促进 AI 检测器鲁棒性的发展，规避和预防滥用风险。

1.3 本文的主要工作

主要工作：

1. 基于跨域交叉奖励的对抗性强化学习算法框架，及其与多个非训练对齐方法的融合。

2. 针对文本改写场景，专门改进了拟人奖励，同时通过结合文本重写质量评估指标的奖励融合，解决了重写人类文本的学习过程中，向不重写、乱重写退化的问题。

3. 构建了相应的增强前后的 AI 文本检测数据集，为 AI 检测器的评估与发展提供可重用价值。

4. 基于上述两套算法搭建相应的对齐生成落地系统。

5. 结合 HC-Var 的理论通过攻防双边验证的充分实验，证明了我们的文本更加拟人，同时也为 AI 文本检测领域带来了攻防双向提升的研究价值。

核心创新点：

1. 结合 HC-Var 的理论，引入跨域交叉奖励改进原生对抗性强化学习，解决奖励过拟合问题。

2. 针对改写任务，进行了专门调优，并引入质量相关的奖励融合解决了重写过程的退化捷径问题。

3. AI 文本检测领域的数据集与基准测试构建层面，我们是首个在保证多样性基础的前提下，对单文本生成进行了对齐增强的工作。

1.4 本文组织结构

本文共分为六个章节，各章节主要内容安排如下：

第一章为 xxx。

...

第六章为 xxx。

第 2 章 相关技术与相关工作

2.1 预训练语言模型

2.1.1 大模型与其他预训练语言模型

1. 介绍 Transformer 模型架构。
2. 介绍大模型结构，decoder only。介绍大模型的自回归生成。
3. 介绍大模型训练过程。介绍大规模预训练与涌现。此时大模型并不具备问答能力，可以认为只具备续写能力。介绍大模型的 SFT + RL。
4. 介绍以 BERT 为主的其他预训练语言模型，encoder only。这类模型易微调，更适合目标明确的分类任务。

2.1.2 大模型 RLHF 与 RLAIIF

1. 介绍 RLHF，尽管 RLHF 对能力提升是最直接有效的，但需要极其大规模的人工标注。
2. 介绍 RLAIIF^[9]，借助对特定任务更有经验和针对性的模型给出的奖励分数。
3. 本文的大模型和检测器间的对抗微调。检测器对于 AI 文本类人程度能够给出更有经验更可靠的分数。同时检测器本身是在同时包含有人类文本和机器文本的数据集上二分类训练得到。某种意义上本文的对抗微调同时结合了 RLHF 和 RLAIIF 的优点。
4. 介绍 RL 相关技术，包括 PPO、DPO、GRPO。GRPO 组内相对奖励有助于拟人程度的对比和学习。

2.2 AI 文本检测与粗粒度类人对齐

2.2.1 AI 文本检测器

介绍两大类检测器：

1. 基于指标的统计分析类方法：这类方法设计指标、划定阈值，进行分类。这类方法没有直接检测文本本身，本质上都是基于困惑度 PPL。优点是不需训练，因此几乎不存在过拟合，泛化能力较强。缺点是不需训练，走捷径，缺少发展性，随大模型发展持续变差。且极易被 hack。

重点强调 Binoculars^[10] 明确汇报了他们对高度随机的机器文本，检测准确率甚至会低至 0。而这类文本几乎完全不具备可读性，与拟人无关。

2. 微调神经网络模型类方法：这类方法直接微调关注语义结构的 BERT 类模型，默认选用实践证明最佳的 RoBERTa。这类方法需要训练，具有更好的发展性，上限检测能力更强，但易过拟合，泛化检测能力不佳，高度依赖于训练集质量。

2.2.2 AI 文本检测数据集与基准测试

1. 过去的 AI 文本检测的 Benchmark 主要侧重于扩展整体数据集分布的多样性(表 2-1)。自 TuringBench^[11] 扩展了多生成器维度以来，用于扩展的维度变得越来越多样化。RuATD^[12] 和 RoFT^[13] 是最早引入多领域维度的工作。HC3^[14] 开创了多语言维度的先河。MGTBench^[15] 和 CHEAT^[16] 率先引入了对抗性考量，而 OpenLLMText^[17] 则是在检测中显式纳入多种解码策略的最早尝试之一。这一演进轨迹在 M4^[18] 处迎来了一个重要里程碑，它全面融合了三个核心维度：多领域、多生成器和多语言。随后，RAID^[8] 进一步推动了该领域的发展，首次全面引入了广泛的对抗性方法，并在涵盖多领域和多生成器维度的同时，将采样策略纳入其中。RealDet^[19] 解决了 RAID 初始版本中缺失多语言支持的问题，但未能覆盖采样策略。

2. 表 2-1 中其他一些 AI 文本检测的 Benchmark 则更专注于特定的研究场景。RuATD、AuText2023^[20]、CCD^[21]、IMDGSP^[22] 和 MultiSocial^[23] 分别致力于针对俄语、西班牙语、源代码、学术论文以及社交媒体文本的 MGT 检测。LLM-DetectAIve^[24]、MixSet^[25] 和 LAMP^[26] 专门关注文本改写攻击，而 Beemo^[1] 通过专家编辑进一步增强了这一方向。MULTITuDE^[27] 首次对跨语系泛化进行了研究，MAGE^[28] 则是第一个为泛化研究建立多个分布外 test bed 的工作。

3. 总而言之，

3.1. 现有的研究更多关注于数据集整体分布的增强，而忽略了单文本生成过程的增强。

3.2. 现有的基于规则的攻击方法更倾向于特殊场景的 hack，例如 RAID 引入了随机修改字母等规则攻击。

但这既不利于 RoBERTa 检测器训练过程的语义学习，不利于整体泛化检测能力的提升。

也不拟人，几乎没有干扰人类阅读对 AI 文本的判别。

2.2.3 粗粒度类人对齐

1. 再次说明，对粗粒度拟人的研究主要集中于 AI 文本检测领域。

1.1. 粗粒度拟人尚无通用的评估方式^[3-4]。

1.2. 一些研究会将绕过 AI 文本检测器检测称作拟人化^[5]，但实际上这只是对某些检测器而言认定为像人类文本^[6]，并不等同于真正意义上的拟人。

2. 重点介绍 HC-Var^[7] 的理论：

2.1. HC-Var 提出相关特征和无关特征的定义，无关特征如文本长度，相关特征指人机文本间潜在的本质差异。

2.2. HC-Var 指出更拟人的机器文本在相关特征上更接近人类文本，有助于 RoBERTa 学到更好的决策边界，增强泛化检测能力。

2.3. HC-Var 还指出 RoBERTa 在同分布检测时会依赖于过拟合的无关特征，而在跨分布泛化检测时基本只能依赖于相关特征。

因此：

根据 HC-Var 的理论，我们就可以借助和 RoBERTa 检测器跨分布的一个对抗性强化学习，来让我们大模型的生成更加拟人。

同样地，根据 HC-Var 的理论，我们也可以通过 AI 文本检测时的攻防双边验证来证明我们的生成是更拟人的。

同时这种拟人增强本身也为该领域研究带来了攻防双边提升双向意义的一个可复用成果。

但弊端在于：

HC-Var 理论虽然可以用于鉴别生成文本是否更加拟人，但无法指示一段文本到底有多拟人、具体什么程度的拟人。

2.3 本章小结

Dataset	Origin Size	Domain Coverage	Model Coverage	Multilingual Coverage	Adversarial Coverage	Sampling Coverage	Alignment Augment
TuringBench ^[11]	200k	✗	✓	✗	✗	✗	✗
RuATD ^[12]	215k	✓	✓	✗	✗	✗	✗
RoFT ^[13]	21k	✓	✓	✗	✗	✗	✗
HC3 ^[14]	26.9k	✓	✗	✓	✗	✗	✗
MGTBench ^[15]	2.8k	✓	✓	✗	✓	✗	✗
CHEAT ^[16]	50k	✗	✗	✗	✓	✗	✗
MULTITuDE ^[27]	74.1k	✗	✓	✓	✗	✗	✗
OpenLLMText ^[17]	340k	✓	✓	✗	✗	✓	✗
AuText2023 ^[20]	160k	✓	✗	✓	✗	✗	✗
CCD ^[21]	467k	✗	✗	✓	✓	✗	✗
IMDGSP ^[22]	29k	✗	✓	✗	✗	✗	✗
M4 ^[18]	122k	✓	✓	✓	✗	✗	✗
HC-Var ^[7]	145k	✓	✗	✗	✗	✗	✗
BUST ^[29]	25k	✓	✓	✗	✗	✓	✗
M4GT-Bench ^[30]	217k	✓	✓	✓	✗	✗	✗
LLM-DetectAIve ^[24]	303k	✓	✓	✗	✓	✗	✗
MixSet ^[25]	3.6k	✓	✓	✗	✓	✗	✗
HC3 Plus ^[31]	210k	✓	✗	✓	✗	✗	✗
MAGE ^[28]	447k	✓	✓	✗	✗	✗	✗
RAID ^[8]	570k	✓	✓	✗	✓	✓	✗
LAMP ^[26]	1k	✓	✓	✗	✓	✗	✗
Beemo ^[11]	19.6k	✓	✓	✗	✓	✗	✗
MultiSocial ^[23]	472k	✓	✓	✓	✗	✗	✗
RealDet ^[19]	847k	✓	✓	✓	✓	✗	✗
MAGA (Ours)	936k	✓	✓	✓	✓	✓	✓

表 2-1 A comparison of the publicly available sources of machine-generated text.

第 3 章 对抗微调为核心的原生 AI 文本对齐增强研究

(备注:来自我的独立一作小论文《MAGA-Bench: Machine-Augment-Generated Text via Alignment Detection Benchmark》。分数处于 borderline 不幸 ACL 未能中稿, 审稿人指出写作要大改, 目前已转投 EMNLP 等待审稿结果。)

3.1 引言

第 1、2 章已提及, 在这里再概括一下。

1. 仅绕过 AI 文本检测器不等同于拟人。
2. 现有 AI 文本检测的 Benchmark 缺少对单文本生成过程的增强。
3. 直接对抗微调由于 RoBERTa 的过拟合而不可行。
4. 结合 HC-Var 的理论, 我们可以通过攻防双边验证来判别是否更加拟人。
5. 结合 HC-Var 的理论, 我们可以通过跨分布交叉奖励解决对抗微调中的奖励过拟合问题。
6. 我们的工作同时有助于促进 AI 文本检测器鲁棒性研究的发展。

3.2 算法设计与实现

3.2.1 目标领域、目标语言与生成器大模型选取设置

介绍图 3-1 中的目标领域、目标语言(中英文)与生成器大模型选取及理由(如选取的领域挑战了大模型哪些不同能力)。

3.2.2 基于跨域交叉奖励的对抗性强化学习算法框架

数学层面介绍图 3-2 算法框架。并结合 HC-Var^[7] 的理论进行解释分析。

3.2.3 对抗性强化学习与非训练对齐方法的集成增强

1. 介绍 BPO^[32] 提示词自动优化算法。
2. 介绍 roleplaying 提示词设计, 角色选取参考了 ROLE-88^[33], 并吸纳了 RRP^[34] 的”Talk Less, Call Right”思想。
3. 介绍 Self Refine^[35] 反思自精炼算法。




图 3-1 Overview of MAGA-Bench. The construction of the dataset encompasses 20 domains, 12 generators, 2 languages and 4 alignment methods. Selected detectors are evaluated on this dataset. Various decoding strategies are also employed, with details provided in Appendix ??.




图 3-2 GDARL and its integration with the **Cross-Mutual Reward (CMR)** component. The term GDARL serves as a collective designation for GDARL-like frameworks and also represents their most general form. The illustration depicts the two standard applications of CMR, namely GDARL-CDMR (Cross Domain Mutual Reward) and GDARL-CMMR (Cross Model Mutual Reward).

4. 介绍图 3-3 我们是怎么将对抗性强化学习与非训练对齐方法的集成增强的。

3.3 实验设置

3.3.1 任务定义

1. 攻击：被选检测器在拟人增强前后的数据集上检测表现指标的平均下滑。




图 3-3 MAGA Pipeline, illustrating the construction process for the MAGA split of the MAGA dataset. MAGA split is the fully enhanced split that integrates all four alignment methods (see Table ??, Appendix ?? for detailed statistics of the splits).

2. 泛化：拟人增强前后的数据集上训练的 RoBERTa 在选取的外部数据集上检测表现指标的平均提升。

3.3.2 数据集

1. 介绍图 3-1 选取的 20 个领域的原始人类文本数据集。
2. 介绍我们拟人前后的数据集的构建过程，这既被用于攻击效果的评估，同时用于训练 RoBERTa 检测器，在外部数据集上检测评估对防守、泛化的评估。
3. 介绍使用的用于泛化检测能力评估的外部数据集 M4^[18]、M4GT^[30]、MAGE^[28]、HC3^[14]。

3.3.3 对比基线

介绍两类 detectors 分别具体选取了哪些，这个选择在 RAID ?? 的基础上扩充了一些近期方法。

如图所示，包括 R-B GPT2 & R-L GPT2^[36]、R-B CGPT^[14]、RADAR^[37]、GLTR^[38]、FastDetectGPT^[39]、Binoculars^[10]、LLMDet^[40]、SCRN^[41]、DETree^[42]、DALD^[43]、GECSCORE^[44]。

3.3.4 评估指标

介绍评估指标 ACC、TPR、TNR、AUC、ACC(@FPR=5%) 及各自的优缺点，主要参考哪个指标。

3.4 实验结果与分析

3.4.1 主要实验

1. 攻击主实验结果及其解读。
2. 泛化主实验结果及其解读。
3. 详细展开的一些实验结果的说明。

3.4.2 消融实验

（注：基于跨域交叉奖励的对抗性强化学习，我们最终使用的是完整的增强形式 GDARL-CDMMR (Generator-Detector Adversarial Reinforcement Learning - Cross Domain & Model Mutual Reward)

1. GDARL-CDMMR 与多个非训练方法融合，消掉每个方法。
2. GDARL-CDMMR 的消融：
 - 2.1. 有无 CDMMR 的效果差异。
 - 2.2. 对抗轮数。
 - 2.3. 交叉的领域分组。
 - 2.4. 交叉的生成器模型分组。

3.4.3 定量与定性分析

1. 多维度定量分析：词法相似度、语法相似度、文本可读性、信息密度、情感一致性。
2. 人类阅读 case study 分析。

3.5 本章小结

第 4 章 AI 重写对齐增强中对抗微调的 针对性改进研究

（备注：这篇是在冯老师建议下我的下一篇小论文，目前核心实验已经做完。其他细节尚未完成，写作也在进行中，预计一个月内完成，目标投稿下半年 ACL 系列会议 (EACL/COLING/NAACL)，这篇偏扩展，主要解决迁移到重写这个特殊的生成领域后发现的问题。）

4.1 引言

1. MAGA 针对的是原生 AI 文本生成，未对重写文本这类特殊形式调优。
2. 日益增多的人机合作文本增大了检测难度，MixSet^[25] 指出常规的二分类检测器是不足够的。
3. 借助重写人类文本这个过程学习差异也有助于让大模型更进一步的拟人。
4. 然而我们发现 GDARL-CDMMR 迁移到重写领域，因为人类文本是最拟人的，对抗使得大模型存在着趋向不重写捷径的错误趋势。

4.2 算法设计与实现

4.2.1 目标领域、目标语言与生成器大模型选取设置

1. 介绍这个选取，与 Beemo^[1] 保持一致。

注：不同于 MAGA，这个领域的工作较少，能够评估的方式也比较固定，在这项工作中，我们和 NAACL 2025 的 Beemo^[1] 的设置保持一致，来实现横向对比。表 4-1 列出了 Beemo 给出的对比表。

4.2.2 面向重写对齐的对抗型强化学习类人对齐奖励分数设计

1. 现有研究明确指出 AI Detection 之所以能成立，是因为生成出来的内容存在某种隐式的 pattern，即拟人程度上，人类文本永远大于机器文本。
2. 我们可以将包括重写的几类文本，按明确的拟人程度进行标序，从 0 到 3 更加拟人的顺序分别是：机器直接生成文本、机器重写的人类文本、人类重写的机器文本、人类文本。

Resource	Size	# Models	Machine-generated & LLM-edited	Machine-generated & Human-edited
TuringBench	200k	19	✗	✗
RoFT	21k	2	✗	✗
MULTITuDE	75k	8	✗	✗
OpenLLMText	340k	5	✗	✗
HC3 Plus	210k	1	✗	✗
MAGE	447k	27	✗	✗
RAID	6.2M	11	✗	✗
MultiSocial	472k	7	✗	✗
BUST	25k	7	✗	✗
M4	122k	6	✗	✗
M4GT-Bench	217k	8	✗	✗
LLM-DetectAIve	303k	14	✓	✗
MixSet	3.6k	8	✓	✓
LAMP	1k	7	✓	✓
Beemo	19.6k	10	✓	✓

表 4-1 注意：这个是 Beemo^[1] 列出的有关重写的 benchmark 对比的表。

3. 这种四分类情况下，怎么对概率分数加权得到一个标量拟人奖励分数是一个问题，我们迁移了专门针对多类别奖励加权的 OPRM 算法^[45]。

4.2.3 面向重写质量的多奖励融合增强

1. 为了保证幅度重写，融合了正则化的编辑距离 NED。
2. 为了确保重写，融合了 BERTScore。
3. 融合加权方式，硬门限还是累乘，直观对比。以及引入 sigmoid 平滑。

4.3 实验设置

4.3.1 任务定义与评估方式

1. 攻防的定义与第 3 章 3.3.1 节类似。
2. 现有检测器一般都是二分类，我们与 Beemo^[1] 保持一致，这个四分类中，两两类别计算 AUC 区分度。

4.3.2 数据集

与第 3 章 3.3.2 类似，介绍原始人类文本数据集、我们的数据集、用于泛化能力评估的外部数据集。

4.3.3 对比基线

介绍被选取的检测器，与 Beemo^[1] 保持一致。

4.4 实验结果与分析

4.4.1 主要实验

1. 攻击主实验结果及其解读。
2. 泛化主实验结果及其解读。
3. 详细展开的一些实验结果的说明。

4.4.2 消融实验

1. 消掉 NED 和 BERTScore。
2. 硬门限与软门限对比。
3. 消掉 sigmoid 平滑。

4.4.3 定量与定性分析

1. 编辑距离算法可标注重写部分、未重写部分，结合检测器向 token-level 概率归因。对比观察分析为什么有效。
2. 人类阅读 case study 分析。

4.5 本章小结

第 5 章 AI 文本对齐增强生成系统的设计、实现和测试

5.1 系统架构设计

画一个系统架构图：

1. 模型部署层：vllm
2. 算法服务层
3. 数据库服务：mysql，存用户信息、账号对话历史
4. 基础功能服务：langchain 多轮对话管理、fastapi 包装接口
5. 前端交互：nginx 反向代理、web 页面框架

5.2 系统实现

5.2.1 整体系统环境实现

1. 前后端、数据库、算法服务、模型部署使用的技术的具体描述。
2. 数据库描述表与 ER 图。

5.2.2 AI 文本对齐增强生成算法服务实现

功能模块图：拟人生成（高频领域可选内置提示词、提示词自动优化用户可选、反思精炼用户可选）、拟人重写、还有检测器归因检测直观看一下可能的拟人程度。

5.3 系统测试

5.3.1 功能测试

使用效果的界面展示与说明。

5.3.2 性能测试

各接口性能测试，包括最大 QPS 和平均响应时间。

5.4 本章小结

第 6 章 总结与展望

6.1 全文总结

6.2 未来展望

参考文献

- [1] ARTEMOVA E, LUCAS J S, VENKATRAMAN S, et al. Beemo: Benchmark of expert-edited machine-generated outputs[C/OL]//CHIRUZZO L, RITTER A, WANG L. Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Albuquerque, New Mexico: Association for Computational Linguistics, 2025: 6992-7018. <https://aclanthology.org/2025.naacl-long.357/>. DOI: 10.18653/v1/2025.naacl-long.357.
- [2] CHEN N, WANG Y, DENG Y, et al. The oscars of ai theater: A survey on role-playing with language models[A/OL]. 2024. <https://arxiv.org/abs/2407.11484>.
- [3] XIAO Y, NG L H X, LIU J, et al. Humanizing machines: Rethinking LLM anthropomorphism through a multi-level framework of design[C/OL]//CHRISTODOULOPOULOS C, CHAKRABORTY T, ROSE C, et al. Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Suzhou, China: Association for Computational Linguistics, 2025: 3331-3350. <https://aclanthology.org/2025.emnlp-main.164/>. DOI: 10.18653/v1/2025.emnlp-main.164.
- [4] CHENG M, YU S, JURAFSKY D. HumT DumT: Measuring and controlling human-like language in LLMs[C/OL]//CHE W, NABENDE J, SHUTOVA E, et al. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025: 25983-26008. <https://aclanthology.org/2025.acl-long.1261/>. DOI: 10.18653/v1/2025.acl-long.1261.
- [5] ZHOU Y, HE B, SUN L. Humanizing machine-generated content: Evading AI-text detection through adversarial attack[C/OL]//CALZOLARI N, KAN M Y, HOSTE V, et al. Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). Torino, Italia: ELRA and ICCL, 2024: 8427-8437. <https://aclanthology.org/2024.lrec-main.739/>.

-
- [6] XU Y E, ZHONG Z, RAGHUNATHAN A, et al. Base models look human to ai detectors[A/OL]. 2026. arXiv: [2605.19516](https://arxiv.org/abs/2605.19516). <https://arxiv.org/abs/2605.19516>.
 - [7] XU H, REN J, HE P, et al. On the generalization of training-based ChatGPT detection methods[C/OL]//AL-ONAIKAN Y, BANSAL M, CHEN Y N. Findings of the Association for Computational Linguistics: EMNLP 2024. Miami, Florida, USA: Association for Computational Linguistics, 2024: 7223-7243. <https://aclanthology.org/2024.findings-emnlp.424/>. DOI: [10.18653/v1/2024.findings-emnlp.424](https://doi.org/10.18653/v1/2024.findings-emnlp.424).
 - [8] DUGAN L, HWANG A, TRHLÍK F, et al. RAID: A shared benchmark for robust evaluation of machine-generated text detectors[C/OL]//KU L W, MARTINS A, SRIKUMAR V. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 12463-12492. <https://aclanthology.org/2024.acl-long.674/>. DOI: [10.18653/v1/2024.acl-long.674](https://doi.org/10.18653/v1/2024.acl-long.674).
 - [9] LEE H, PHATALE S, MANSOOR H, et al. Rlaif vs. rlhf: Scaling reinforcement learning from human feedback with ai feedback[A/OL]. 2024. arXiv: [2309.00267](https://arxiv.org/abs/2309.00267). <https://arxiv.org/abs/2309.00267>.
 - [10] HANS A, SCHWARZSCHILD A, CHEREPANNOVA V, et al. Spotting llms with binoculars: zero-shot detection of machine-generated text[C/OL]//ICML'24: Proceedings of the 41st International Conference on Machine Learning. Vienna, Austria: JMLR.org, 2024. <https://dl.acm.org/doi/abs/10.5555/3692070.3692768>.
 - [11] UCHENDU A, MA Z, LE T, et al. TURINGBENCH: A benchmark environment for Turing test in the age of neural text generation[C/OL]//MOENS M F, HUANG X, SPECIA L, et al. Findings of the Association for Computational Linguistics: EMNLP 2021. Punta Cana, Dominican Republic: Association for Computational Linguistics, 2021: 2001-2016. <https://aclanthology.org/2021.findings-emnlp.172/>. DOI: [10.18653/v1/2021.findings-emnlp.172](https://doi.org/10.18653/v1/2021.findings-emnlp.172).
 - [12] SHAMARDINA T, MIKHAILOV V, CHERNIANSKII D, et al. Findings of the the ruatd shared task 2022 on artificial text detection in russian[C/OL]//Computational Linguistics and Intellectual Technologies. RSUH, 2022: 497 - 511. <http://dx.doi.org/10.28995/2075-7182-2022-21-497-511>.

- [13] DUGAN L, IPPOLITO D, KIRUBARAJAN A, et al. Real or fake text? investigating human ability to detect boundaries between human-written and machine-generated text[C/OL]//AAAI'23/IAAI'23/EAAI'23: Proceedings of the Thirty-Seventh AAAI Conference on Artificial Intelligence and Thirty-Fifth Conference on Innovative Applications of Artificial Intelligence and Thirteenth Symposium on Educational Advances in Artificial Intelligence. AAAI Press, 2023. <https://doi.org/10.1609/aaai.v37i11.26501>.
- [14] GUO B, ZHANG X, WANG Z, et al. How close is chatgpt to human experts? comparison corpus, evaluation, and detection[A]. 2023. arXiv: [2301.07597](https://arxiv.org/abs/2301.07597).
- [15] HE X, SHEN X, CHEN Z, et al. Mgtbench: Benchmarking machine-generated text detection[A]. 2023. arXiv: [2303.14822](https://arxiv.org/abs/2303.14822).
- [16] YU P, CHEN J, FENG X, et al. Cheat: A large-scale dataset for detecting chatgpt-written abstracts[A/OL]. 2023. arXiv: [2304.12008](https://arxiv.org/abs/2304.12008). <https://arxiv.org/abs/2304.12008>.
- [17] CHEN Y, KANG H, ZHAI V, et al. Token prediction as implicit classification to identify LLM-generated text[C/OL]//BOUAMOR H, PINO J, BALI K. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 13112-13120. <https://aclanthology.org/2023.emnlp-main.810/>. DOI: [10.18653/v1/2023.emnlp-main.810](https://doi.org/10.18653/v1/2023.emnlp-main.810).
- [18] WANG Y, MANSUROV J, IVANOV P, et al. M4: Multi-generator, multi-domain, and multi-lingual black-box machine-generated text detection[C/OL]//GRAHAM Y, PURVER M. Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers). St. Julian's, Malta: Association for Computational Linguistics, 2024: 1369-1407. <https://aclanthology.org/2024.eacl-long.83/>. DOI: [10.18653/v1/2024.eacl-long.83](https://doi.org/10.18653/v1/2024.eacl-long.83).
- [19] ZHU X, REN Y, CAO Y, et al. Reliably bounding false positives: A zero-shot machine-generated text detection framework via multiscaled conformal prediction[C/OL]//CHE W, NABENDE J, SHUTOVA E, et al. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025: 12298-12319. <https://aclanthology.org/2025.acl-long.601/>. DOI: [10.18653/v1/2025.acl-long.601](https://doi.org/10.18653/v1/2025.acl-long.601).

- [20] SARVAZYAN A M, GONZÁLEZ J Á, FRANCO-SALVADOR M, et al. Overview of autextification at iberlef 2023: Detection and attribution of machine-generated text in multiple domains[A]. 2023. arXiv: [2309.11285](https://arxiv.org/abs/2309.11285).
- [21] WANG J, LIU S, XIE X, et al. Evaluating aigc detectors on code content[A]. 2023. arXiv: [2304.05193](https://arxiv.org/abs/2304.05193).
- [22] MOSCA E, ABDALLA M H I, BASSO P, et al. Distinguishing fact from fiction: A benchmark dataset for identifying machine-generated scientific papers in the LLM era.[C/OL]//OVALLE A, CHANG K W, MEHRABI N, et al. Proceedings of the 3rd Workshop on Trustworthy Natural Language Processing (TrustNLP 2023). Toronto, Canada: Association for Computational Linguistics, 2023: 190-207. <https://aclanthology.org/2023.trustnlp-1.17>. DOI: [10.18653/v1/2023.trustnlp-1.17](https://doi.org/10.18653/v1/2023.trustnlp-1.17).
- [23] MACKO D, KOPÁL J, MORO R, et al. MultiSocial: Multilingual benchmark of machine-generated text detection of social-media texts[C/OL]//CHE W, NABENDE J, SHUTOVA E, et al. Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025: 727-752. <https://aclanthology.org/2025.acl-long.36/>. DOI: [10.18653/v1/2025.acl-long.36](https://doi.org/10.18653/v1/2025.acl-long.36).
- [24] ABASSY M, ELOZEIRI K, AZIZ A, et al. LLM-DetectAIve: a tool for fine-grained machine-generated text detection[C/OL]//HERNANDEZ FARIAS D I, HOPE T, LI M. Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. Miami, Florida, USA: Association for Computational Linguistics, 2024: 336-343. <https://aclanthology.org/2024.emnlp-demo.35/>. DOI: [10.18653/v1/2024.emnlp-demo.35](https://doi.org/10.18653/v1/2024.emnlp-demo.35).
- [25] ZHANG Q, GAO C, CHEN D, et al. LLM-as-a-coauthor: Can mixed human-written and machine-generated text be detected?[C/OL]//DUH K, GOMEZ H, BETHARD S. Findings of the Association for Computational Linguistics: NAACL 2024. Mexico City, Mexico: Association for Computational Linguistics, 2024: 409-436. <https://aclanthology.org/2024.findings-naacl.29/>. DOI: [10.18653/v1/2024.findings-naacl.29](https://doi.org/10.18653/v1/2024.findings-naacl.29).
- [26] CHAKRABARTY T, LABAN P, WU C S. Can ai writing be salvaged? mitigating idiosyncrasies and improving human-ai alignment in the writing process through

- edits[C/OL]//Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems. 2025: 1-33. <https://dl.acm.org/doi/full/10.1145/3706598.3713559>.
- [27] MACKO D, MORO R, UCHENDU A, et al. MULTITuDE: Large-scale multilingual machine-generated text detection benchmark[C/OL]//BOUAMOR H, PINO J, BALI K. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9960-9987. <https://aclanthology.org/2023.emnlp-main.616>. DOI: [10.18653/v1/2023.emnlp-main.616](https://doi.org/10.18653/v1/2023.emnlp-main.616).
- [28] LI Y, LI Q, CUI L, et al. MAGE: Machine-generated text detection in the wild [C/OL]//KU L W, MARTINS A, SRIKUMAR V. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 36-53. <https://aclanthology.org/2024.acl-long.3/>. DOI: [10.18653/v1/2024.acl-long.3](https://doi.org/10.18653/v1/2024.acl-long.3).
- [29] CORNELIUS J, LITHGOW-SERRANO O, MITROVIC S, et al. BUST: Benchmark for the evaluation of detectors of LLM-generated text[C/OL]//DUH K, GOMEZ H, BETHARD S. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Mexico City, Mexico: Association for Computational Linguistics, 2024: 8029-8057. <https://aclanthology.org/2024.naacl-long.444/>. DOI: [10.18653/v1/2024.naacl-long.444](https://doi.org/10.18653/v1/2024.naacl-long.444).
- [30] WANG Y, MANSUROV J, IVANOV P, et al. M4GT-bench: Evaluation benchmark for black-box machine-generated text detection[C/OL]//KU L W, MARTINS A, SRIKUMAR V. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 3964-3992. <https://aclanthology.org/2024.acl-long.218/>. DOI: [10.18653/v1/2024.acl-long.218](https://doi.org/10.18653/v1/2024.acl-long.218).
- [31] SU Z, WU X, ZHOU W, et al. Hc3 plus: A semantic-invariant human chatgpt comparison corpus[A]. 2024. arXiv: [2309.02731](https://arxiv.org/abs/2309.02731).
- [32] CHENG J, LIU X, ZHENG K, et al. Black-box prompt optimization: Aligning large language models without model training[C/OL]//KU L W, MARTINS A, SRIKUMAR V. Proceedings of the 62nd Annual Meeting of the Association for

- Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 3201-3219. <https://aclanthology.org/2024.acl-long.176/>. DOI: 10.18653/v1/2024.acl-long.176.
- [33] CHOW W Y, SMITH C, LAU E, et al. A “bag-of-arguments” mechanism for initial verb predictions[J/OL]. *Language, Cognition and Neuroscience*, 2016, 31 (5): 577-596. https://discovery.ucl.ac.uk/id/eprint/1471143/1/Chow-et-al_2015_Bag-of-Arguments.pdf.
- [34] RUANGTANUSAK S, TAVEEKITWORACHAI P, PIPATANAKUL K. Talk less, call right: Enhancing role-play llm agents with automatic prompt optimization and role prompting[A/OL]. 2025. arXiv: 2509.00482. <https://arxiv.org/abs/2509.00482>.
- [35] MADAAN A, TANDON N, GUPTA P, et al. Self-refine: Iterative refinement with self-feedback[C/OL]//OH A, NAUMANN T, GLOBERSON A, et al. *Advances in Neural Information Processing Systems: Vol. 36*. Curran Associates, Inc., 2023: 46534-46594. https://proceedings.neurips.cc/paper_files/paper/2023/file/91edff07232fb1b55a505a9e9f6c0ff3-Paper-Conference.pdf.
- [36] SOLAIMAN I, BRUNDAGE M, CLARK J, et al. Release strategies and the social impacts of language models[M/OL]. arXiv, 2019. <https://arxiv.org/abs/1908.09203>. DOI: 10.48550/ARXIV.1908.09203.
- [37] HU X, CHEN P Y, HO T Y. Radar: Robust ai-text detection via adversarial learning[C/OL]//OH A, NAUMANN T, GLOBERSON A, et al. *Advances in Neural Information Processing Systems: Vol. 36*. Curran Associates, Inc., 2023: 15077-15095. https://proceedings.neurips.cc/paper_files/paper/2023/file/30e15e5941ae0cdab7ef58cc8d59a4ca-Paper-Conference.pdf.
- [38] GEHRMANN S, STROBELT H, RUSH A. GLTR: Statistical detection and visualization of generated text[C/OL]//COSTA-JUSSÀ M R, ALFONSECA E. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics: System Demonstrations*. Florence, Italy: Association for Computational Linguistics, 2019: 111-116. <https://aclanthology.org/P19-3019>. DOI: 10.18653/v1/P19-3019.
- [39] BAO G, ZHAO Y, TENG Z, et al. Fast-detectGPT: Efficient zero-shot detection of machine-generated text via conditional probability curvature[C/OL]//The Twelfth

- International Conference on Learning Representations. 2024. <https://openreview.net/forum?id=Bpcgcr8E8Z>.
- [40] WU K, PANG L, SHEN H, et al. LLMDet: A third party large language models generated text detection tool[C/OL]//BOUAMOR H, PINO J, BALI K. Findings of the Association for Computational Linguistics: EMNLP 2023. Singapore: Association for Computational Linguistics, 2023: 2113-2133. <https://aclanthology.org/2023.findings-emnlp.139>. DOI: 10.18653/v1/2023.findings-emnlp.139.
- [41] HUANG G, ZHANG Y, LI Z, et al. Are AI-generated text detectors robust to adversarial perturbations?[C/OL]//KU L W, MARTINS A, SRIKUMAR V. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 6005-6024. <https://aclanthology.org/2024.acl-long.327/>. DOI: 10.18653/v1/2024.acl-long.327.
- [42] HE Y, ZHANG S, CAO Y, et al. Detree: Detecting human-ai collaborative texts via tree-structured hierarchical representation learning: abs/2510.17489[A/OL]. 2025. <https://api.semanticscholar.org/CorpusID:282209720>.
- [43] ZENG C, TANG S, YANG X, et al. Dald: Improving logits-based detector without logits from black-box llms[C/OL]//GLOBERSON A, MACKEY L, BELGRAVE D, et al. Advances in Neural Information Processing Systems: Vol. 37. Curran Associates, Inc., 2024: 54947-54973. https://proceedings.neurips.cc/paper_files/paper/2024/file/62e5f22b5dae99ec700be622df4fbe0d-Paper-Conference.pdf. DOI: 10.52202/079017-1743.
- [44] WU J, ZHAN R, WONG D F, et al. Who wrote this? the key to zero-shot LLM-generated text detection is GECScore[C/OL]//RAMBOW O, WANNER L, APID- IANAKI M, et al. Proceedings of the 31st International Conference on Computational Linguistics. Abu Dhabi, UAE: Association for Computational Linguistics, 2025: 10275-10292. <https://aclanthology.org/2025.coling-main.684/>.
- [45] CHEN L, WANG L, SHAN R, et al. Learning ordinal probabilistic reward from preferences[C/OL]//The Fourteenth International Conference on Learning Representations. 2026. <https://openreview.net/forum?id=0Vf5trUAVF>.

致 谢

致谢

复旦大学 学位论文独创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。论文中除特别标注的内容外，不包含任何其他个人或机构已经发表或撰写过的研究成果。对本研究做出重要贡献的个人和集体，均已在论文中作了明确的声明并表示了谢意。本声明的法律结果由本人承担。

作者签名：_____ 日期：_____

复旦大学 学位论文使用授权声明

本人完全了解复旦大学有关收藏和利用博士、硕士学位论文的规定，即：学校有权收藏、使用并向国家有关部门或机构送交论文的印刷本和电子版本；允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其它复制手段保存论文。涉密学位论文在解密后遵守此规定。

作者签名：_____ 导师签名：_____ 日期：_____